[수치해석] Data fitting

Appoximation fittint에 해당하는 부분이다.

- 어느 정도의 에러를 허용한다.
- 실제 데이터는 Noise가 있기 때문에 데이터를 정확히 맞추는 것이 더 안 좋을 수 있다.
    - Exact fitting처럼 모든 데이터를 통과하면 Noise까지 학습하여 Overfitting이 발생한다.
- 어떤 Noise 모델을 가정하는 지에 따라서 결과가 달라진다.
- Generalization 측면에서 좋다.

Interpolation과 **Approximation fitting**을 비교하면 다음과 같다.

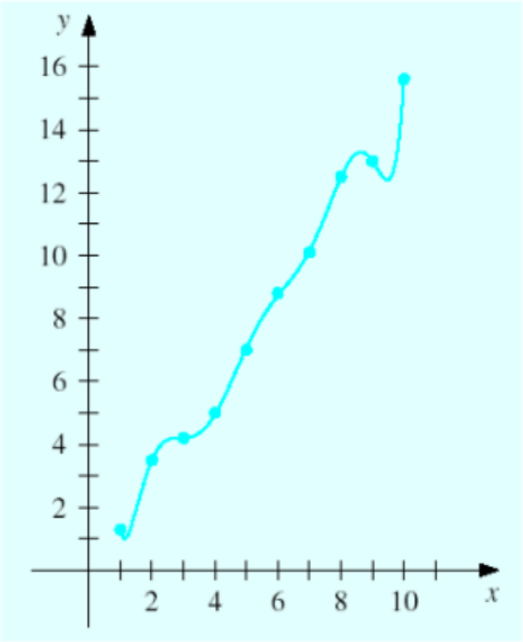

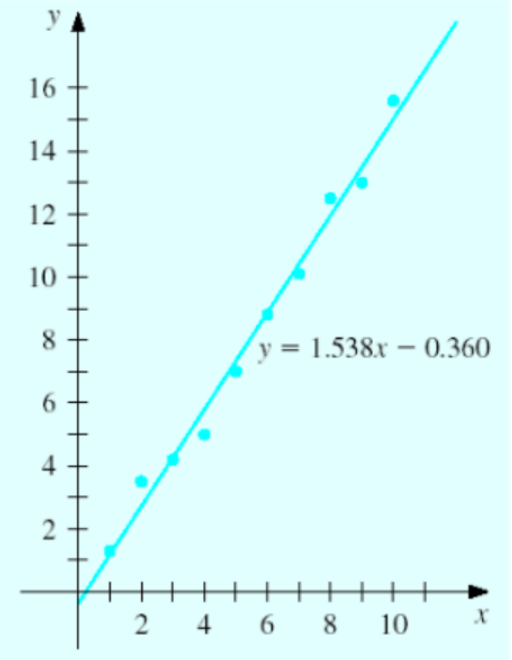

Regression에서 모델의 구조에 따른 **Error**를 분석해보자.

- **Regression:** 입력 x가 주어졌을 때 연속적인 출력 y를 예측하는 방법

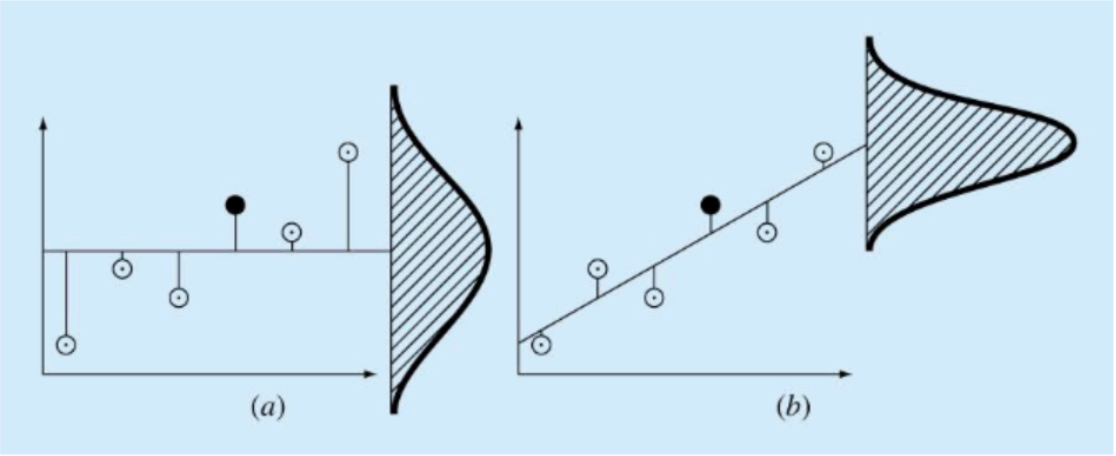

Zero-order model 1st-order model

Zero-order model은 **y = c (c는 상수)인 모델**이다.

- Residual의 분포가 넓고 낮은 것을 확인할 수 있다.

1st-order model은 **y = ax + b인 모델**이다.

- Residual의 분포가 좁고 높은 것을 확인할 수 있다.
  - 비교적 간단해진다.
- 분포가 **대칭적/정규분포 형태**로 가까워진다.

즉, **모델이 복잡해질수록 Residual이 단순해지는 것**을 확인할 수 있다.

- Noise는 실제 데이터에 포함되어져 있다.
  - $y = f(x) + \epsilon$
  - $\epsilon = y - f(x)$
- 하지만 실제 데이터의 Noise를 모르고 대응되는 모델 $f(x)$도 모르기 때문에 Residual만 계산한다.
  - **Residual** = $y - \hat{y} = (f(x) + \epsilon) - \hat{f(x)}$ = $y - \hat{f(x)}$
- **모델이 복잡해질수록 $\hat{f(x)}$와 $f(x)$가 비슷해져 Residual이 실제 Noise와 비슷해지고 Noise가 단순해 보이게 된다.**

    - 따라서 **Residual을 Noise의 Modeling**이라고 할 수 있다.
    - **실제 Noise를 모르기 때문에 Residual을 Noise의 근사치로 활용**한다.
        - Regression model이 충분히 좋다면, **Noise** $\sim$ **Residual**이기 때문이다.
- 따라서 모델에 따라 **Residual**이 달라져 보인다.
    - 사용자가 선택한 모델 구조에 따라 Residual은 자동으로 결정된다.
    - 우리는 Noise를 직접 관측하지 못하여 Residual을 이용하여 근사하는데, **Residual이 모델에 의해 변화하기 때문이다.**

Noise model: 데이터에 섞여 있는 Noise가 어떤 확률 분포를 따르는 지에 대한 모형

- **실제 Noise가 이런 분포를 가질 것이라고 가정**
- **Residual의 분포와 가정한 Noise model이 다르다면 모델 성능이 좋지 않다.**

결국 **Residual을 최소화하는 Parameter를 찾아 Model을 구성하는 것이 Approximation fitting의 목표**이다.

이때, **가정한 Noise model에 따라 그에 맞는 형태의 Loss를 사용**한다.

- $y = f(x) + \epsilon$에서 어떤 Noise model을 정의 하는지에 따라 확률 $P(Y|X)$의 분포 형태가 달라진다.
    - 평균이 $f(x)$인 것만 동일하다.
- Loss를 최소화한다는 것은 Maximum likelihood를 하는 것과 동일하고 NLL을 사용할 수 있다.
    - Loss의 형태는 확률 분포의 영향을 받을 수 밖에 없다.
- 이때 $P(Y|X)$ 형태가 다르기 때문에 Noise model이 결과를 결정할 수 있는 것이다.

그 Loss를 최소화하면 Residual이 가정한 Noise model과 최대한 가까워지도록 모델이 학습된다.

Data fitting 방법들에 대해 알아보자.

Least-Square Data fitting

> **Loss function으로 오차의 제곱을 사용하는 방법**

Data: $\sum_{i=1}^{N}(X_i, Y_i)$, Parameter 개수: M, Parameter = $[a_1, a_2, ..., a_N]$

Least square: $S = \sum_{i=1}^{N}[(Y_i - y(X_i; a)]^2$을 최소화하는 Parameter를 찾는 것

- y가 모델
- Polynomial, y = ax + b 등 다양한 모델을 사용할 수 있다.

Error를 $e_i = Y_i - y(X_i; a)$라고 할 때, **모든 데이터가 서로 독립이고 Noise (error)가 Gaussian이라면 Least square는 Maximum Likelihood와 동일**하다.

- Residual (Noise)가 Gaussian이라면 $p(y_i|x_i) = N(y(x_i; a), \sigma)$이다.
- **i.i.d** 가정으로 인해 Likelihood $P(Y|X) = \Pi_{i=1}^{N}(P(Y_i|X_i)$이다.
- Maximum likelihood를 위해 **Negative log likelihood**를 하면 Least square의 식과 동일해진다.

Chi-Square Data fitting

> **각 Data point의 불확실성을 반영하는 Least square**

$$S = \sum_{i=1}^{N}[\frac{Y_i - y(X_i; a)}{\sigma_i}]^2$$

- 각 Data의 불확실성이 σ를 통해 표현된다.

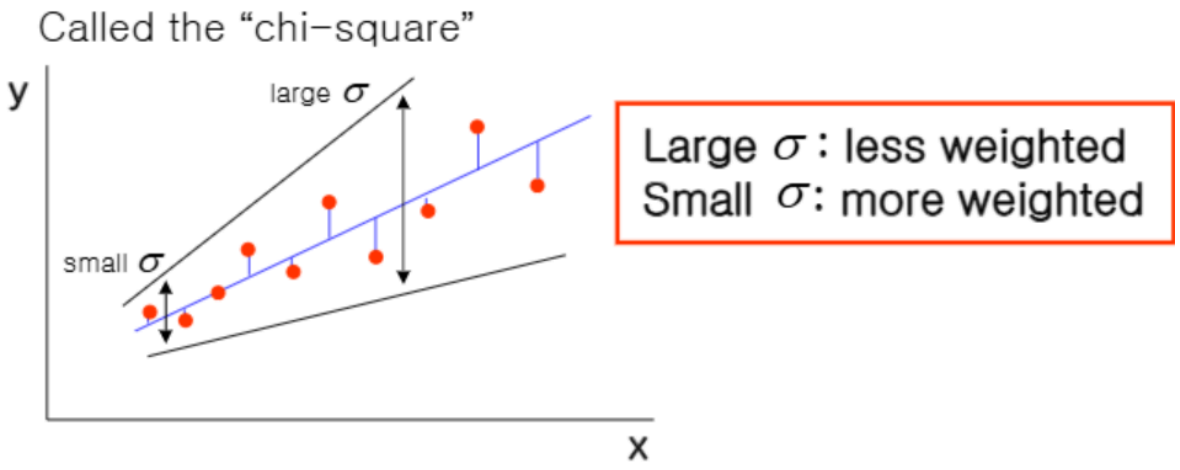

- 불확실성 (σ)가 큰 데이터에 가중치를 덜 주는 방식이다.
- 확실한 Data로 Training하고자 하는 것이다.

Generalization of Linear Least Square

Model: $y = \sum_{i=1}^{M} c_i f_i(x_i)$

- c_i: 계수, f_i: Basis function
- **c에 대해 Linear해야 한다.**

Loss는 다음과 같다.

$$S = \sum_{i=1}^{N} [Y_i - \sum_{i=1}^{M} c_i f_i(x_i)]^2$$

이를 미분하여 c를 구하도록 하면 $J^T J c = J^T y$가 나온다.

$$\mathbf{J}^{\mathrm{T}} = \begin{bmatrix} \frac{\partial e_1}{\partial c_1} & \frac{\partial e_2}{\partial c_1} & \cdots & \frac{\partial e_N}{\partial c_1} \\ \frac{\partial e_1}{\partial c_2} & \ddots & & \frac{\partial e_N}{\partial c_2} \\ \vdots & & \ddots & \vdots \\ \frac{\partial e_1}{\partial c_M} & \frac{\partial e_2}{\partial c_M} & \cdots & \frac{\partial e_N}{\partial c_M} \end{bmatrix} = -\begin{bmatrix} f_1(x_1) & f_1(x_2) & \cdots & f_1(x_N) \\ f_2(x_1) & \ddots & & f_2(x_N) \\ \vdots & & \ddots & \vdots \\ f_M(x_1) & f_M(x_2) & \cdots & f_M(x_N) \end{bmatrix}$$

$J^T Jc = J^T y$ 식으로 C를 찾는 것은 **1D Least square**뿐만 아니라, **Multi-Dimension Least square**에서도 동일하다.

- f_i의 입력이 스칼라인지 벡터인지 차이밖에 없다.

즉, 모델이 파라미터에 대해 선형인 경우, Linear Equation으로 파라미터를 구할 수 있다.

그렇다면, **Parameter에 대해 Non-linear한 모델**은 어떻게 다룰 수 있을까?

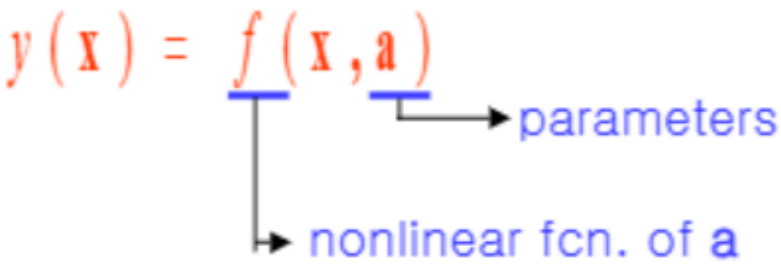

$$y = f(x_1, x_2, a_1, a_2, a_3, a_4)$$

$$= x_1 + a_3 x_2 - \frac{a_2}{a_4} x_1^2 + \frac{a_1}{a_4} x_1 x_2 - a_2 x_4$$

Non-linear한 경우에는 Linaer equation을 통해 파라미터를 구할 수 없다.

1. Easy case

> **쉽게 Linear한 형태로 변환하여 Least square에서 얻은 Linear equation을 통해 파라미터를 구할 수 있는 경우**

$y = \alpha e^{\beta x}$라는 Non-linear model을 생각해보자.

양변에 로그를 취하면 다음과 같다.

- $lny = ln\alpha + \beta x$
- **Linearization**

여기서 $y' = lny, \alpha' = ln\alpha$ 이라고 하면 다음과 같은 Linear model이 된다.

- $y' = \alpha' + \beta x$

Linear한 모델을 통해 얻은 Linear equation으로 Parameter를 구할 수 있다.

그러나 **이 방법은 Log를 취함으로써 Noise model 구조 자체를 변화시키기 때문에, Optimum Solution을 찾지 못 한다.**

여러 **Linearization 방법이 있다.**

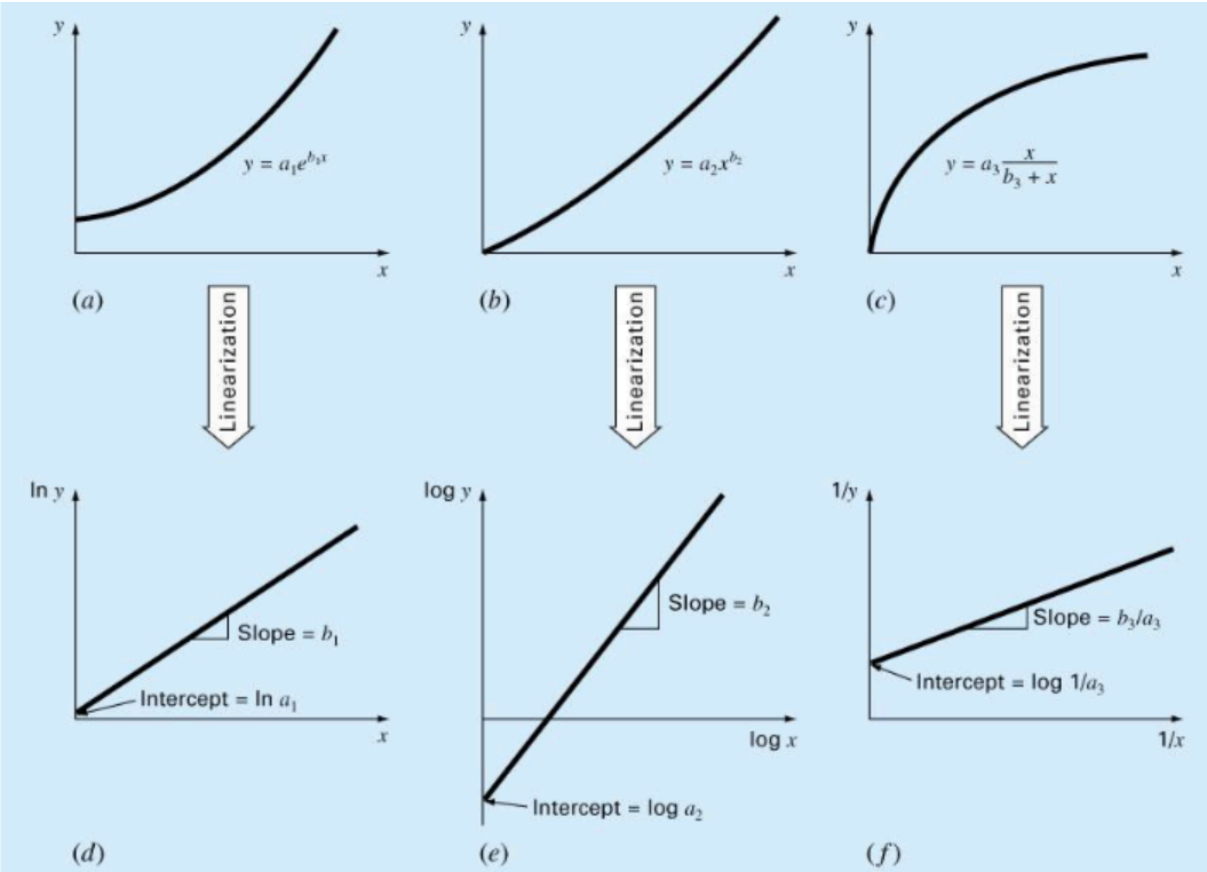

2. Hard case

Model이 $y = f(x, a)$일 때, 아래 **Cost function**이 최소가 되도록 하는 Parameter a를 **Iterative method**로 찾아야 한다.

$$x^2(a) = \sum_{i=1}^{N} [\frac{y_i - f(x_i, a)}{\sigma_i}]^2$$

a^*을 찾아야 한다.

$$a^* = argmin_a x^2(a)$$

Parameter a를 찾는 **Iterative method에 대해 알아보자.**

Levenberg–Marquardt Method

> **최적점에서 멀 때는 Steepest descent를 이용하여 가까울 때는 Inverse Hessian을 이용하는 방법**

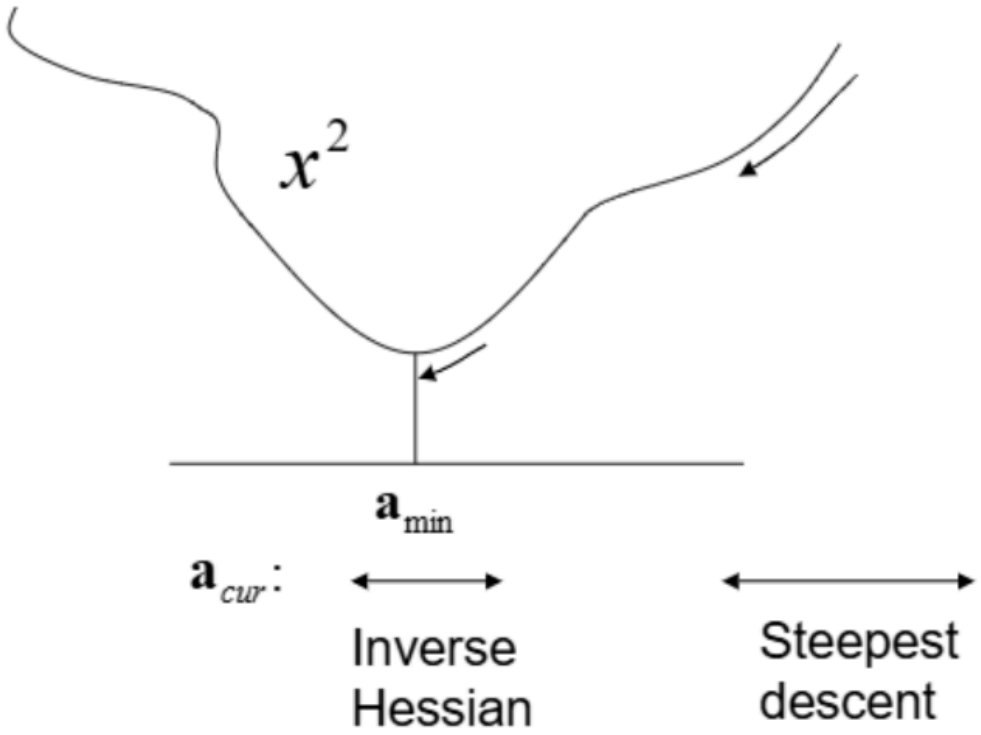

- a_{cur}: 현재 a의 위치

Steepest descent

$$\Delta a = -const \cdot \nabla x^2$$

Inverse Hessian

cost function $x^2(a)$를 Taylor 전개로 근사하면 다음과 같다.

$$x^2(a) \approx x^2(a_{cur}) + \nabla x^2(a_{cur})^T \Delta a + \frac{1}{2}\Delta a^T H \Delta a$$

최솟값에서의 기울기는 0이기 때문에, $\nabla x^2(a_{min}) = 0$이다.

$$\nabla x^2(a_{min}) = \nabla x^2(a_{cur}) + H\Delta a = 0$$

위 식을 정리하면 아래와 같다.

$$H\Delta a = -\nabla x^2(a_{cur})$$

따라서 $\Delta a = H^{-1}\nabla x^2(a_{cur})$이고, Δa만큼 Update하는 방법이다.

과정

1. 초깃값 (a_{cur})을 정한다.

2. Cost function ($x^2(a_{cur})$)와 Graident를 계산한다.

3. λ를 정한다.

4. $(H + \lambda I)\Delta a = -\nabla x^2(a_{cur})$의 Linear equation을 계산하여 Δa를 얻는다.
   - λ가 클수록 Steepest descent처럼 동작
   - λ가 작을수록 Inverse Hessian method처럼 동작

5. (4)번에서 Update 결과 $x^2(a_{cur} + \Delta a) > x^2(a_{cur})$ 라면 λ를 10배 증가하여 더 Steepest descent처럼 동작하도록 만든다. $x^2(a_{cur} + \Delta a) < x^2(a_{cur})$ 라면 λ를 10배 감소하여 더 Inverse Hessian method처럼 동작하도록 만든다.

(4)번에서 λ가 매우 커지면 **Diagonal dominant**해지고 $H + \lambda I \sim \lambda I$가 된다.

이때, $\Delta a = -\lambda^{-1}\nabla x^2(a_{cur})$가 되는데, λ^{-1}**을 Learning rate라고 생각하면 Steepest descent와 동일**하다는 것을 확인할 수 있다.

Robust data fitting

> **Least square가 Outlier에 약하기 때문에 사용하는 방법**

Least sqaure는 에러의 제곱을 모두 합하기 때문에 Outlier가 있다면 Loss가 커지게 된다.

1. Robust Measure (Loss funciton) 사용

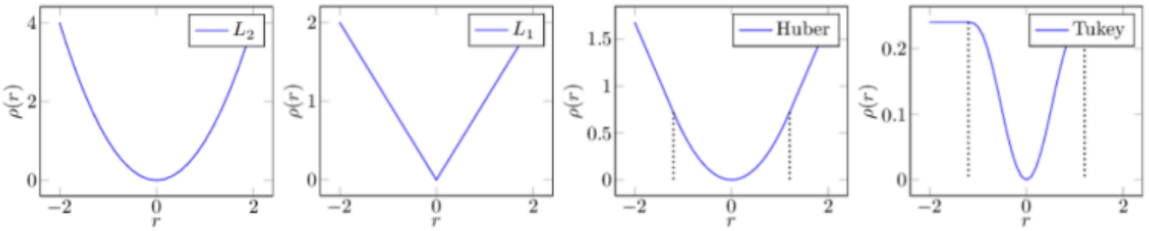

L2 (가장 왼쪽에 비해) 나머지 3가지 Loss는 Robust하다.

r: Residual일 때, 각 Loss의 계산 방법을 알아보자.

1. **L2**: r^2
2. **L1**: $|r|$
3. **Huber:** 작은 r에는 L2, 큰 r에는 L2을 적용
4. **Tukey**: $\rho(r) = flat$ when $|\ r\ | > c$
    - Outlier의 loss는 상수

2. Random sampling 사용

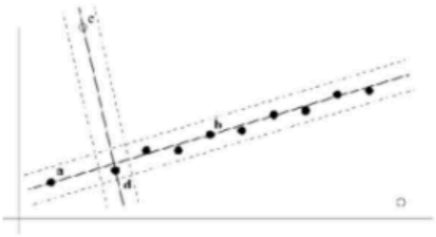

RANdom SAmple Consensus:
RANSAC determines the consistency of a hypothesis by counting the number of points within a threshold RANSAC determines the consistency of a hypothesis by counting the number of points within a threshold distance (given by the dashed line).

1. 전체 데이터에서 모델을 정의할 수 있는 최소 개수로 이루어진 데이터를 Random하게 Sampling 한다.
2. (1)의 데이터로 Model을 얻는다.
3. 얻은 모델로 전체 데이터에 대해 계산하고, 오차가 임계값 이하라면 Inliner라고 판단한다.
4. (1) ~ (3) 과정을 계속 반복하며, (3)에서 가장 많은 Inliner를 갖는 모델을 선택한다.

Inlier가 많을수록 좋은 모델이라고 판단하는 방법이다.